


Оптимизация архитектуры МоЕ: прокси-метрики важности

Подготовили Арсеньев С., Зыбинский И., Тушин И., Вольнов М., Морозов А.

Руководитель - Бессонницын Е.С.




Вычислительная сложность прунинга и концепция прокси-метрик

Проблема

- **Избыточность архитектуры:** Многие слои MoE работают вхолостую, почти не меняя вход, их можно удалить без потери точности.
- **Тупик метода Ablation:** Поочередное отключение слоев и прогон через бенчмарки для прунинга - это долго и дорого

Идея проекта

- **Отказ от прямого тестирования:** Заменить прогон бенчмарков на вычисление дешевой математической функции.
- **Прокси-метрики:** Мы за один проход модели по экзамену ищем физический паттерн, который укажет на бесполезность слоя.



План работы

Шаг 1. Подготовка датасета и подбор метрик


Шаг 2. Обучение тестовой прокси-метрики

Шаг 3. Генерализация прокси-метрики на другой архитектуре

Шаг 4. Анализ результатов, новые прокси-метрики

Шаг 5. Новый валидационный датасет

Шаг 6. Анализ результатов и точки роста



Шаг 1.1. Подготовка датасета


Бенчмарк: CommonsenseQA (CSQA)

- **Оптимальный объем:** 1221 вопрос с вариантами ответа — достаточно для надёжности статистики и считается относительно быстро.
- **Специфика:** Тестирует понимание логики физического мира, что является отличным маркером базовой работоспособности модели до оптимизации.

Объект исследования: Qwen1.5-MoE-A2.7B

- **Архитектурная эффективность:** Из 14.3B параметров при Forward Pass активируются только 2.7B, это ускоряет вычисления.
- **Результаты:** Показывает точность на уровне Mistral 7B (около 70% на CSQA), но требуеткратно меньше GPU-ресурсов для прогона.

Для формирования целевой переменной мы провели **ablation study**: замерыли падение точности при поочередном отключении каждого из 24 слоёв Qwen при прогоне на CSQA.



Шаг 1.2. Подбор метрик

Мы выбрали 9 метрик и посчитали их усредненные значения между скрытыми состояниями Qwen при решении CSQA.

Абсолютные изменения (амплитуда)

- **MSE** (Среднеквадратичная ошибка)
- **L₁** (Манхэттенское расстояние)
- **L_∞** (Max-Absolute, пиковые выбросы)


Векторные сдвиги (направление)

- **Cosine Distance** (Сонаправленность)
- **Pearson Correlation** (Линейная зависимость)
- **Residual Contribution** (Доля удлинения)

Структурная информация

- **СКА** (Centered Kernel Alignment - похожесть внутренней структуры)
- **Variance Ratio** (Изменение дисперсии)
- **Router Entropy** (Энтропия маршрутизатора MoE)

Qwen 1.5 MoE (Commonsense): Metric Correlations



Шаг 1.2. Подбор метрик

Абсолютные изменения (амплитуда)

$$\text{MSE} = \frac{1}{d} \sum_{i=1}^d \left(h_i^{(l-1)} - h_i^{(l)} \right)^2$$

$$L_1 = \sum_{i=1}^d \left| h_i^{(l-1)} - h_i^{(l)} \right|$$

$$L_\infty = \max_{1 \leq i \leq d} \left| h_i^{(l-1)} - h_i^{(l)} \right|$$

Структурная информация

$$\text{CKA}(H^{(l-1)}, H^{(l)}) = \frac{\|(H^{(l)})^T H^{(l-1)}\|_F^2}{\|(H^{(l-1)})^T H^{(l-1)}\|_F \|(H^{(l)})^T H^{(l)}\|_F}$$

$$\text{VR} = \frac{\text{Var}(\mathbf{h}^{(l)})}{\text{Var}(\mathbf{h}^{(l-1)})}$$

$$H = - \sum_{j=1}^E p_j \log p_j$$

Векторные сдвиги (направление)

$$D_{\cos} = 1 - \frac{\mathbf{h}^{(l-1)} \cdot \mathbf{h}^{(l)}}{\|\mathbf{h}^{(l-1)}\|_2 \|\mathbf{h}^{(l)}\|_2}$$

$$r = \frac{\sum_{i=1}^d (h_i^{(l-1)} - \bar{h}^{(l-1)})(h_i^{(l)} - \bar{h}^{(l)})}{\sqrt{\sum_{i=1}^d (h_i^{(l-1)} - \bar{h}^{(l-1)})^2} \sqrt{\sum_{i=1}^d (h_i^{(l)} - \bar{h}^{(l)})^2}}$$

$$\text{RC} = \frac{\|\mathbf{h}^{(l)} - \mathbf{h}^{(l-1)}\|_2}{\|\mathbf{h}^{(l-1)}\|_2}$$


Здесь $\mathbf{h}^{(l)}$ — вектор скрытого состояния (hidden state) отдельного токена на l -том слое (вектор признаков), а $\mathbf{H}^{(l)}$ — матрица скрытых состояний всех токенов

Шаг 2. Обучение тестовой прокси-метрики

Для предсказания падения точности обучена линейная регрессия на основе 9 прокси-метрик. Оптимизация проводилась методом градиентного спуска (Loss = MSE). Итоговая прокси-метрика демонстрирует высокую предсказательную способность: коэффициент Пирсона 0.71, ранговая корреляция Спирмена 0.76 (по модулю).

Веса регрессионной модели:

$$\begin{aligned}\text{Ablation}^{(l)} = & 0.7280 \cdot L_1(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & - 0.6287 \cdot D_{\cos}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.6283 \cdot r(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.4512 \cdot L_{\infty}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.2983 \cdot \text{MSE}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.1063 \cdot H^{(l)} \\ & + 0.0540 \cdot \text{RC}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.0400 \cdot \text{VR}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.0205 \cdot \text{CKA}(H^{(l-1)}, H^{(l)})\end{aligned}$$




Шаг 3. Генерализация прокси-метрики на другой архитектуре

Для проверки устойчивости (генерализации) метода к смене архитектуры была проведена валидация на модели **Phi-Tiny-MoE** (3.8B всего / 1.1B активных параметров). Перенос регрессии, обученной на Qwen, показал сохранение высокой ранговой корреляции (Спирмен 0.71), несмотря на падение линейной зависимости (Пирсон 0.44).

Выводы по первой метрике:

- **Ранговая устойчивость:** Падение Пирсона при стабильном Спирмене означает, что метрика корректно сортирует слои по важности, хотя абсолютные значения предсказаний искажаются. Главный критерий для прунинга — именно ранги.
- **Фильтрация шума:** Часть из 9 метрик не значима (коэффициенты малы). Необходим строгий отбор признаков.
- **Нелинейная природа:** Превосходство Спирмена указывает на нелинейный характер зависимости падения точности от активаций. Перспективный шаг — переход к полиномиальным моделям.



Шаг 4.1. Поиск нелинейных зависимостей (Полиномиальная регрессия)

Проблема:

Превосходство ранговой корреляции над линейной указывает на нелинейный характер зависимости падения точности от метрик. Линейные модели такую зависимость не учитывают.


Решение:

Полиномиальная регрессия: Мы построили полином второго порядка из 9 исходных метрик. Обучение также проводилось градиентным спуском.

Результат:

Получена избыточная модель с 54 параметрами. Она показала высокую ранговую корреляцию (0.79) на базовой архитектуре Qwen, но заметно просела (до 0.70) при переносе на Phi-Tiny. Это прямо свидетельствует о переобучении из-за обилия шумовых параметров.

$$\begin{aligned}\text{Ablation}^{(l)} = & 0.2526 \cdot \text{CKA}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot D_{L_1}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & - 0.2474 \cdot D_{\cos}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot \text{CKA}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & - 0.1643 \cdot D_{\cos}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot r(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.1235 \cdot D_{L_1}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot r(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.1176 \cdot \text{CKA}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot L_{\infty}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.1139 \cdot L_{\infty}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot r(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.1013 \cdot r^2(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.0941 \cdot \text{CKA}^2(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + 0.0914 \cdot \text{CKA}(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \cdot r(\mathbf{h}^{(l-1)}, \mathbf{h}^{(l)}) \\ & + \dots\end{aligned}$$



Шаг 4.2. Отбор признаков и борьба с переобучением (LASSO)

Проблема:

Наши базовые 9 метрик не учитывают положение слоя в архитектуре сети, а какие-то почти не вносят вклад в метрику.

Решение:


Расширение признаков: Для каждой метрики (кроме Router Entropy) добавлен контекст (разница с соседними слоями - prev/next, с краями сети - first/last и общая статистика - mean/std).

Отсев шума: На полученных 49 признаках для каждого слоя обучена LASSO-регрессия с L_1 -регуляризацией – регрессия, оставляющая только “важные” признаки. Это позволяет избежать переобучения.

Результат:

Модель убрала шумовые параметры, оставив 6 самых значимых метрик (из 49), и повысила ранговую корреляцию до 0.80 (и дала 0.86 ранговой корреляции на Phi-Tiny, что указывает на хорошую переносимость метрики).

$$\begin{aligned}\text{Ablation}^{(l)} = & 0.3426 \cdot D_{\cos}^{\text{first}}(\mathbf{h}^{(l)}) \\ & + 0.2066 \cdot \text{VR}^{\text{prev}}(\mathbf{h}^{(l)}) \\ & - 0.2059 \cdot D_{\cos}^{\text{last}}(\mathbf{h}^{(l)}) \\ & + 0.1922 \cdot D_{\cos}^{\text{std}}(\mathbf{h}^{(l)}) \\ & + 0.0471 \cdot L_{\infty}^{\text{next}}(\mathbf{h}^{(l)}) \\ & + 0.0056 \cdot r^{\text{last}}(\mathbf{h}^{(l)})\end{aligned}$$




Шаг 4. Итоговые результаты на CSQA

Ключевые наблюдения:

- LASSO показывает лучшую ранговую корреляцию (**0.80** на Qwen и **0.86** на Phi-Tiny). Это одна из ключевых характеристик для задач прунинга.
- LASSO не переобучилась под конкретную сеть.
- Полиномиальная модель в контексте прунинга не хуже LASSO – у них почти одинаковые результаты предсказания топ-5 неважных слоёв.
- Несмотря на хорошую ранговую корреляцию, метрики не слишком успешно выделяют топ-5 неважных слоёв. Они видят картину в целом, но не фокусируются на “выбросах”.

Модель	Прокси-метрика	Пирсон	Пирсон (p-value)	Спирмен	Спирмен (p-value)	Средняя ошибка ранжирования	Угадано из топ-5 ненужных
Qwen 1.5 MoE (24L)	Proxy_Metric	-0.7080	0.0001	-0.7621	0.0	3.42	2
Phi-Tiny (32L)	Proxy_Metric	-0.4424	0.0112	-0.7070	0.0	5.44	1
Qwen 1.5 MoE (24L)	Poly_Proxy	-0.7575	0.0000	-0.7938	0.0	3.17	4
Phi-Tiny (32L)	Poly_Proxy	-0.4679	0.0069	-0.7085	0.0	5.62	1
Qwen 1.5 MoE (24L)	Lasso_Proxy	-0.7932	0.0000	-0.8038	0.0	3.25	3
Phi-Tiny (32L)	Lasso_Proxy	-0.6512	0.0001	-0.8617	0.0	3.81	1
Qwen 1.5 MoE (24L)	Lasso_Rank_Proxy	-0.7732	0.0000	-0.7986	0.0	3.25	3
Phi-Tiny (32L)	Lasso_Rank_Proxy	-0.6234	0.0001	-0.8637	0.0	3.81	1




Шаг 5. Новый валидационный датасет

Для проверки обобщающей способности наших метрик на другие экзамены мы взяли экзамен **Social Interaction QA (SIQA)**. Он тестирует понимание социальной логики и мотивов людей, что принципиально отличается от специфики CSQA.

На нём наши прокси-метрики без дообучения показали результаты местами даже лучше, чем на CSQA, что ещё раз говорит о их хорошей обобщающей способности. На этом экзамене LASSO обошла все остальные метрики по всем параметрам.

Ограничения переноса: На Phi-Tiny на новом экзамене наблюдается просадка рангов. Это показывает, что хотя метрики обобщается на новые задачи, они всё же несколько привязаны к архитектуре, и для большей точности при смене архитектуры их лучше калибровать.

Модель	Прокси-метрика	Пирсон	Пирсон (p-value)	Спирмен	Спирмен (p-value)	Средняя ошибка ранжирования	Угадано из топ-5 ненужных
Qwen 1.5 MoE (24L)	Proxy_Metric	-0.7823	0.0000	-0.8724	0.0000	2.62	2
Phi-Tiny (32L)	Proxy_Metric	-0.3628	0.0413	-0.5572	0.0009	6.44	1
Qwen 1.5 MoE (24L)	Poly_Proxy	-0.8041	0.0000	-0.8811	0.0000	2.71	3
Phi-Tiny (32L)	Poly_Proxy	-0.3697	0.0373	-0.5878	0.0004	6.72	1
Qwen 1.5 MoE (24L)	Lasso_Proxy	-0.8672	0.0000	-0.9167	0.0000	2.12	3
Phi-Tiny (32L)	Lasso_Proxy	-0.5562	0.0009	-0.7117	0.0000	5.53	2
Qwen 1.5 MoE (24L)	Lasso_Rank_Proxy	-0.7831	0.0000	-0.9185	0.0000	1.79	3
Phi-Tiny (32L)	Lasso_Rank_Proxy	-0.5269	0.0019	-0.7163	0.0000	5.47	2



Шаг 6. Анализ результатов и точки роста

Результаты

- **Эффективность ансамблей:** Одиночные метрики неинформативны, но их комбинация через LASSO-регрессию дает устойчивую прокси-метрику с корреляцией Спирмена 0.71–0.91.
- **Универсальность:** Метод доказал свою применимость на разных архитектурах и данных, что подтверждает его фундаментальный характер.
- **Скорость:** Вычисление прокси-метрики в десятки раз быстрее, чем прямой Ablation Study, что позволяет проводить аудит нейросетей быстро и дешево.
- **Интерпретируемость:** Благодаря отбору признаков мы выяснили механику деградации (выделив 6 главных структурных признаков из 49). Процесс прунинга перестал быть «чёрным ящиком».

Точки роста и коммерциализация

- **Бинарная классификация:** Переход от регрессии к бинарному классификатору «Safe-to-Drop». Задача сужается до точного определения 5 наиболее бесполезных слоев, что может повысить надежность коммерческого инструмента для прунинга.
- **Прунинг подмножеств:** Исследование влияния удаления не одиночных слоев, а подмножеств. Это расширит датасет и откроет новые возможности для feature-инжиниринга.
- **Динамический пропуск:** Прокси-метрики можно использовать для принятия решения о пропуске слоя прямо во время работы модели в зависимости от сложности входного промпта.
- Отбор признаков в полиномиальной модели?

Источники

Исследования прунинга:

1. Gromov, A., et al. (2024). The Unreasonable Ineffectiveness of the Deeper Layers.
2. Kornblith, S., et al. (2019). Similarity of Neural Network Representations Revisited.
3. Men, X., et al. (2024). ShortGPT: Layers in Large Language Models are More Redundant Than You Expect.

Архитектуры исследуемых моделей:

4. Bai, J., et al. / Alibaba Group (2023–2024). Qwen Technical Report.
5. Gunasekar, S., et al. / Microsoft (2023). Textbooks Are All You Need.

Используемые датасеты:

6. Talmor, A., et al. (2019). CommonsenseQA: A Question Answering Challenge Targeting Commonsense Knowledge.
7. Sap, M., et al. (2019). Social IQA: Commonsense Reasoning about Social Interactions.

Наш репозиторий:

